

《大数据技术基础》课程

关于大模型助力大数据分析案例的实施细则

说明

一、AI 辅助开发工具范围补充

可以使用 Cursor、Windsurf、OpenAI Codex、Claude Code、OpenClaw、CoPaw等 AI 辅助编程工具。

二、Agent 与 Skills 额外加分条件

在原有 **20 分** 评分额度之外，鼓励学生将大模型能力用于可复用、可验证的大数据分析 workflow。若小组或个人在项目全过程中合理使用 **AI Agent**，并将可复用功能封装为 **Skills**，可获得额外加分，**最高不超过 5 分**。该加分不替代原有评分项，缺少研究实践报告、源代码、数据文件等核心材料时，不得仅凭 Agent 或 Skills 获得加分。

加分细则如下：

- **Agent 工作流使用 (1 分)**：在数据采集、清洗入库、可视化、统计分析或报告生成等环节中，实际使用 AI Agent 完成多步骤任务，并提交任务目标、关键提示词或对话摘要、工具调用记录、命令运行结果或截图，以及人工审核说明。
- **Skills 封装质量 (2 分)**：将项目中可复用功能封装为至少 1 个 Skill，例如网页数据爬取 Skill、数据清洗入库 Skill、可视化生成 Skill、统计分析 Skill、报告生成 Skill 等。
- **自动化复用效果 (2 分)**：Skill 能在项目中被实际调用并完成可验证流程，建议覆盖“爬取数据—清洗入库—可视化—分析报告”中的至少两个环节，并提供运行日志、结果截图、生成文件或复现实验说明。

三、提交与合规要求补充

若申请 Agent 与 Skills 额外加分，应在原有提交材料基础上补充 AI 工具使用说明、Skills 目录或 SKILL.md 文件、运行日志、截图或输入输出样例。

为鼓励选课学生积极参加大模型助力大数据分析案例分享，对完成研究实践及课堂分享的小组及个人予以加分认定，特制定本实施细则。

一、分享形式

提交研究实践报告以及源代码，并完成**15 分钟以内**的课堂分享（以PPT形式）。研究实践报告需严格按照附表2的模板书写，在报告或PPT都需要配以适当截图辅助说明，**做到图文并茂**。

二、分享主题

本次案例分享聚焦于**医疗与金融两大领域**，同学们可以围绕这些领域自由发挥，探索具体的应用场景。通过使用Cursor、WindSurf等智能编程工具，以及与大模型交互得到对数据的文字和可视化分析，体验大模型助力大数据分析的过程。

三、分享内容及分值额度

在给定的分享主题下自拟题目，各部分内容以及对应分值额度参见下表，总分为20分。

各部分内容	各部分分值额度
爬虫数据采集	根据质量，分值在5-7 分
数据分析	根据质量，分值在1-3 分
数据可视化（鼓励使用第2种方式v0.dev平台实现可视化）	根据质量，分值在4-6 分
整体分析	根据质量，分值在2-4 分

给分细则

1. 爬虫数据采集（5-7分）

评分维度：数据源（爬取的目标网站）质量、数据完整性、代码规范性、工具使用情况

7分：

- 数据源：数据源权威且丰富，覆盖多个相关领域或多个时间维度（如多年度数据、多地区数据等）。
- 数据量：采集的数据量大，能够满足后续分析和挖掘的需求。
- 代码规范性：代码逻辑清晰，注释详细，遵循编程规范，易于理解和维护。
- 工具使用：使用了智能编程工具（如Cursor、WindSurf等）进行代码撰写和调试，代码高效且无明显错误。
- 实践报告：在实践报告中明确给出了源网站链接，并对数据采集过程进行了详细说明，包括数据源的选择理由、爬取策略、数据清洗和预处理的具体步骤。

6分：

- 数据源较为丰富，但可能在权威性或多样性上略有不足。
- 数据采集基本完整，但可能存在少量缺失或需要进一步修正的地方。
- 使用了智能编程工具，代码较为规范，但可能在逻辑上有小瑕疵。
- 数据清洗和预处理基本完成，数据质量良好。
- 实践报告：在实践报告中给出了源网站链接，但对数据采集过程的说明不够详细，部分步骤可能需要进一步补充。

5分：

- 数据源单一或权威性不足。
- 数据采集存在明显缺失或错误，但进行了必要的清洗和预处理。
- 未使用智能编程工具，代码存在较多问题（如逻辑混乱、效率低）。
- 数据质量一般，可能需要进一步优化才能用于后续分析。
- 实践报告：源网站实际页面解析与代码不匹配，或对数据采集过程的说明过于简略，缺乏关键信息。

（注：缺少数据源网站、采集代码、数据结果、实践报告截图中任意一项，会在5分基础上依次递减）

2. 数据分析（1-3分）

评分维度：分析方法的多样性、分析结果的准确性、分析的深度

3分：

- 综合对数据进行多角度分析（如描述性统计、时间序列分析、相关性分析、聚类分析等），至少涵盖4种以上。
- 分析结果准确，能够清晰地展示数据特征和趋势。
- 分析具有深度，能够从数据中挖掘出有价值的见解或发现潜在问题。

2分：

- 使用了2-3种分析角度，但可能在某些角度的运用上不够深入或准确。
- 分析结果基本准确，能够展示部分数据特征，但缺乏深度。
- 分析角度之间缺乏逻辑连贯性，未形成完整的分析体系。

1分：

- 只使用了1-2种分析角度，且角度选择不合理或运用不准确。
- 分析结果存在明显错误或无法有效展示数据特征。
- 分析过程缺乏逻辑性，未对数据进行深入挖掘。

3. 数据可视化（4-6分）

评分维度：图表类型多样性、维度指标合理性、交互功能丰富性、可视化效果

6分：

- 包含了3-5种不同类型的图表（如柱状图、折线图、饼图、散点图、地图等），图表选择合理，能够清晰地展示数据特征。
- 维度指标设计合理，能够从多个角度展示数据，且逻辑清晰。
- 交互功能丰富，如支持筛选、缩放、悬停显示详细信息等，用户体验良好。
- 使用了v0.dev平台或类似工具实现可视化，效果美观且具有一定的创新性。

5分：

- 包含了3-4种图表类型，但可能在某些图表的选择上不够合理。
- 维度指标设计基本合理，但可能在某些地方不够完善。
- 交互功能较为丰富，但可能在用户体验上存在小瑕疵。
- 可视化效果良好，但缺乏一定的创新性。

4分：

- 只包含了2-3种图表类型，且图表选择可能较为单一。
- 维度指标设计简单，未能充分展示数据的多维度特征。
- 交互功能较少或交互设计不合理，用户体验一般。
- 可视化效果一般。

4. 整体分析（2-4分）

评分维度：应用方向的创新性、可行性分析的深度、整体价值的体现

4分：

- 应用方向：提出了至少2种创新且可落地的应用方向（例如：智能金融风险预警系统、基于大数据的智能投资组合优化、基于多源数据的疾病预测与早期干预），每个方向都具有较高的实用价值，能够紧密结合实际场景（如金融、医学等领域）。
- 可行性分析：可行性分析深入，考虑了技术可行性、成本效益、市场需求、数据可用性等多方面因素，论证充分，有具体数据或案例支持。
- 整体价值：对整个项目的潜在价值进行了全面分析，能够清晰展示从爬虫到可视化的全流程对目标领域的贡献和意义，具有较强的说服力。

3分：

- 提出了2种应用方向，但可能在创新性或实用性上略有不足。
- 可行性分析：可行性分析较为全面，但论证深度不够，缺乏与前期数据爬取和分析工作的联系，部分因素的考虑不够充分。
- 整体价值：对项目的潜在价值进行了分析，但分析不够深入，未能充分展示全流程对目标领域的贡献。

2分：

- 只提出了1种应用方向，或提出的2种方向都缺乏创新性和实用性。
- 可行性分析：可行性分析简单，未考虑关键因素或缺乏论证，整体论证不够合理。
- 整体价值：对项目的潜在价值分析不足，未能清晰展示其对目标领域的贡献，整体说服力较弱。

爬虫数据采集

- 目标网站要求：
 - 包含2-4个不同的网站
 - 数据总量：医疗和金融场景各不少于1000条有效数据
- 开发流程规范：
 - 需提交与大模型的完整对话记录截图（含错误调试过程）
 - 关键代码段需注释说明大模型的贡献点
- 输出要求：
 - 代码文件压缩包
 - 大模型对话截图（放入**案例分享报告**中）
 - CSV数据文件（UTF-8编码）
 - 字段说明（写成表格，插入**案例分享报告**中）

参考截图

```
def fetch_data(url, headers, cookies, proxies):
    """Fetch data from a given URL with headers, cookies, and proxies"""
    with urllib.request.urlopen(url, headers=headers, cookies=cookies, proxies=proxies) as response:
        data = response.read().decode('utf-8')
        return data

def parse_data(data):
    """Parse the fetched data into a structured format"""
    # Parsing logic here
    return parsed_data
```

日期	国际资本流动(亿美元)	铁路公司收入(亿美元)	政府基建投资(亿美元)	私人交通投资(亿美元)	航空公司利润(亿美元)		
2025-12-22	1895.35	188.45	1735.2	1458.7	5.98	21.35	
2025-12-28	1812.84	185.72	1684.2	289.4	1423.6	5.33	26.98
2025-12-05	1735.29	185.96	1623.5	284.7	1388.4	5.41	20.17
2025-12-04	1895.42	133.16	1788.5	337.5	1412.3	6.45	22.15
2025-12-03	1842.87	138.26	1891.7	346.9	1508.6	7.28	23.84
2025-12-22	1888.14	135.33	1741.6	333.1	1488.5	6.92	21.88
2025-12-01	1786.19	182.85	1632.4	315.9	1314.7	5.93	21.47
2025-12-28	1778.82	188.42	1638.2	318.6	1385.2	5.95	21.43
2025-12-19	1889.75	188.62	1687.5	323.1	1375.9	6.12	21.25
2025-12-18	1913.88	133.41	1733.8	328.9	1482.3	6.58	22.81
2025-12-17	2086.35	137.29	1982.6	351.9	1539.4	7.27	23.15
2025-12-16	2083.23	133.12	1887.9	348.6	1531.7	7.25	22.47
2025-12-15	2043.75	148.83	1887.5	328.4	1558.2	6.42	23.19
2025-12-14	2084.85	132.56	2045.7	331.2	1713.5	5.96	23.15
2025-12-13	1852.74	185.93	1724.6	288.5	1426.8	5.47	20.84
2025-12-12	1732.95	97.46	1585.2	271.2	1312.5	5.88	19.45
2025-12-11	1858.92	184.73	1732.8	295.4	1437.5	5.83	20.89
2025-12-10	1882.47	188.12	1536.4	265.2	1294.7	4.95	19.12
2025-12-09	1788.34	183.25	1683.9	277.9	1396	5.27	20.34
2025-12-8	1932.87	112.96	1817.6	308.5	1509.1	6.82	21.78
2025-12-7	1812.12	188.89	1724.2	291.5	1432.8	5.98	20.96
2025-12-6	1765.29	98.34	1638.7	274.6	1364.1	5.15	19.83
2025-12-5	1883.74	188.45	1779.2	301.8	1477.4	5.92	21.45
2025-12-4	1738.62	98.82	1682.1	268.5	1333.6	4.97	19.27
2025-12-3	1786.25	182.27	1688.5	285.7	1402.7	5.98	20.55
2025-12-2	1887.85	138.28	1785.4	297.4	1488.4	5.84	21.63
2025-12-1	1732.49	98.45	1632.6	272.9	1351.7	5.11	19.68
2024-12-31	1889.25	95.34	1588.2	268.8	1319.4	4.75	18.92

数据可视化

- 图表类型：
 - 包含3-5种类型（折线图/柱状图/饼图/热力图/散点图等）
- 可视化方式选择：（以下三种可任选其一）
 - 方式1：部署AJ-Report平台，在**案例分享报告**提交如右图所示的数据大屏截图
 - 方式2：使用v0.dev平台<https://v0.dev/chat>，通过与大模型交互，得到数据可视化界面，在**案例分享报告**提交提示词+右图所示的数据大屏截图
 - 方式3：自己搭建一套前后端，提供源代码和前端Web数据图表截图



提示词：请根据以下结构化数据生成可视化方案，要求使用shadcn UI组件库和React框架：
数据结构时间序列数据
7个维度指标：
• 国际资本流动(亿美元)
• 铁路公司收入(亿美元)
• 公路运输收入(亿美元)
• 政府基建投资(亿美元)
• 私人交通投资(亿美元)
• 航空公司利润(亿美元)
• 航空公司股价(美元)
可视化要求使用shadcn UI组件(Card/Grid/Tooltip等) 构建响应式布局
采用Recharts/Victory等React图表库实现：
• 主趋势折线图 (资本流动+基建投资)
• 对比柱状图 (运输收入 vs 利润)
• 双轴图 (股价指标)
添加交互功能：
• 日期范围选择器
• 指标切换
• 数据悬停详情
样式规范遵循shadcn暗色主题

四、完成方式

小组合作完成或个人独立完成。

五、额度分配及材料提交

小组合作完成：组长提交《研究实践报告+PPT》、数据文件（压缩包形式）、代码文件（压缩包形式），组长在研究实践报告给出组内成员分工（附表1）。

个人独立完成：个人提交《研究实践报告+PPT》、数据文件（压缩包形式）、代码文件（压缩包形式）。

六、其他

- （一）本细则于2026 年 3 月 4 日经《大数据技术基础》教学团队讨论通过，自 2026 年春季学期起施行。
- （二）本细则由《大数据技术基础》教学团队负责解释。

附表1：《组内分工表

分享题目	
给分明细（此处不需要填写，由助教老师统一打分）	爬虫数据采集（5-7分） / 数据分析（1-3分） / 数据可视化（4-6分） / 整体分析（2-4分） / 合计

分工明细

序号	姓名	学号	负责工作	备注
1	张三	2022xxxxxx	爬虫数据采集和数据分析	组长
2	李四	2022xxxxxx	对采集数据进行清洗和预处理	
3	王五	2022xxxxxx	数据可视化	

附表2：《研究实践报告》（示例模板）

一、爬虫数据采集		
【大模型的完整对话记录截图（含错误调试过程）】		
【爬取的数据文件各个字段的说明，写成表格样式，如下所示】		
字段名称	单位	描述
跨区域患者流动量	万人次	当日跨行政区划就医、转诊或流行病学追踪的患者总量
三甲医院日接诊量	万人次	三级甲等医院当日接诊患者总量（含门诊、急诊）
基层医疗转运总量	万人次	社区卫生服务中心/乡镇卫生院完成的患者转运总量（含救护车与非急救转运）
二、数据分析		
【四类分析说明+与大模型交互截图】		
三、数据挖掘		
【文字内容+与大模型交互截图】		
四、数据可视化		
【至少五类图表截图+说明文字】		